

AnalystLab Africa — Experience Lab

Initial Analysis Document

HealthConnect Clinic — Appointment No-Show Analysis

Data Analytics — Semaine 4

1. Dataset Overview

Le jeu de données HealthConnect_Appointment_Data.csv contient 5 000 rendez-vous, décrits par 18 variables couvrant la démographie du patient, les détails du rendez-vous, l'historique du patient, les informations de rappel, la distance à la clinique, le temps d'attente, et le résultat du rendez-vous (variable cible).

Variable	Catégorie	Interprétation
appointment_id	Identifiant	Identifiant unique du rendez-vous
patient_id	Identifiant	Identifiant unique du patient
gender	Démographie	Genre du patient
age	Démographie	Âge du patient (18-80 ans dans le dataset)
age_group	Démographie	Tranche d'âge, probablement dérivée de age
appointment_type	Détails RDV	Type de consultation
booking_date	Booking	Date à laquelle le RDV a été pris
appointment_date	Détails RDV	Date du RDV
appointment_day	Détails RDV	Jour de la semaine du RDV
appointment_time	Détails RDV	Heure du RDV
booking_lead_days	Booking	Délai en jours entre réservation et RDV (0-60 jours)
previous_appointments	Historique	Nombre de RDV précédents du patient (0-11)
previous_no_shows	Historique	Nombre de no-shows précédents du patient (0-5)
reminder_sent	Rappel	Un rappel a-t-il été envoyé (Oui/Non)
reminder_channel	Rappel	Canal du rappel (SMS, email, appel...)
distance_to_clinic_km	Contexte	Distance domicile-clinique en km (0,5-45 km)
waiting_time_minutes	Contexte	Temps d'attente le jour du RDV (2-68 min)
appointment_outcome	Résultat	Variable cible : Attended / No-Show / Cancelled

Interprétation générale : le dataset couvre bien les catégories de facteurs classiquement associées aux no-shows dans la littérature (historique patient, délai de réservation, rappels, distance), ce qui en fait une base solide pour l'analyse à venir.

2. Data Quality Assessment

Dimensions	5 000 lignes × 18 colonnes
Doublons (lignes complètes)	0
Répartition de appointment_outcome	No-Show : 2 423 (48,46%) Attended : 2 314 (46,28%) Cancelled : 263 (5,26%)

2.1 Valeurs manquantes

Colonne	Valeurs manquantes	% du dataset
reminder_channel	1 366	27,32 %
distance_to_clinic_km	90	1,80 %
waiting_time_minutes	60	1,20 %
Toutes les autres colonnes	0	0,00 %

Observation clé : l'absence de valeur sur reminder_channel concerne 27,32% des rendez-vous — une proportion trop importante pour être un simple défaut de saisie. Hypothèse à vérifier en Semaine 5 : ces valeurs manquantes correspondent probablement aux rendez-vous où reminder_sent = 'Non' (absence de rappel envoyé, donc logiquement aucun canal renseigné). Si confirmé, il ne s'agit pas d'une donnée manquante au sens strict mais d'une valeur structurellement absente, qui devra être recodée (ex: 'Aucun rappel') plutôt que supprimée ou imputée.

Les valeurs manquantes sur distance_to_clinic_km (1,80%) et waiting_time_minutes (1,20%) sont marginales et compatibles avec de simples erreurs de saisie ou de capture ponctuelles ; un traitement standard (suppression des lignes concernées ou imputation par la médiane) sera suffisant.

2.2 Anomalies et points de vigilance

- Aucune valeur aberrante évidente détectée sur les variables numériques (âge 18-80 ans, délai de réservation 0-60 jours, distance 0,5-45 km, temps d'attente 2-68 minutes) — les plages semblent réalistes et cohérentes avec un contexte clinique.
- booking_lead_days minimum = 0 : à vérifier si cela correspond à des rendez-vous pris le jour même (plausible) plutôt qu'à une erreur de calcul de date.
- Le taux de no-show de 48,46% est extrêmement élevé comparé aux standards du secteur santé (généralement 10-30% selon les études) — à confirmer si ce chiffre reflète un choix de conception du dataset fictif ou une situation réaliste à traiter comme telle dans le cadre du projet.

3. Questions Business Pertinentes

- Quelle est l'ampleur globale du problème de no-show à HealthConnect Clinic, et comment varie-t-elle selon les caractéristiques du patient et du rendez-vous ?
- L'envoi d'un rappel (et son canal) réduit-il le taux de no-show ?
- Le délai entre la prise de rendez-vous et le rendez-vous lui-même influence-t-il le risque de no-show ?
- Les patients ayant un historique de no-shows répètent-ils ce comportement ?
- La distance à la clinique constitue-t-elle un frein à l'assiduité ?
- Certains types de rendez-vous, jours de la semaine ou créneaux horaires sont-ils plus à risque de no-show que d'autres ?

4. KPIs Potentiels (liés aux questions business)

Conformément aux consignes de la Semaine 4, ces KPIs sont identifiés et justifiés à ce stade, mais ne sont pas encore calculés ni visualisés — cela fera l'objet des phases d'analyse suivantes.

KPI Potentiel	Question Business Associée	Justification
Taux de No-Show Global	Quelle est l'ampleur réelle du problème des rendez-vous manqués ?	Point de référence indispensable avant toute analyse plus fine ; avec 48,46% de no-shows observés, c'est le premier signal à quantifier formellement.
Taux de No-Show par Statut de Rappel (envoyé / non envoyé)	L'envoi d'un rappel réduit-il concrètement le risque de no-show ?	27,32% des rendez-vous n'ont aucun canal de rappel renseigné — comprendre si le rappel a un effet mesurable orienterait directement une action opérationnelle simple (systématiser les rappels).
Taux de No-Show par Tranche de Délai de Réservation (booking_lead_days)	Un délai de réservation plus long est-il associé à un risque de no-show plus élevé ?	Le délai varie de 0 à 60 jours (moyenne ~30j) ; un délai long est un facteur de risque classique dans la littérature sur les no-shows médicaux, à vérifier sur ce dataset.
Taux de No-Show selon l'Histoire de No-Shows du Patient (previous_no_shows)	Le comportement passé du patient prédit-il son comportement futur ?	Une moyenne de 0,54 no-show précédent par patient suggère un sous-groupe récidiviste ; si confirmé, ce critère serait un signal d'alerte précoce exploitable.
Taux de No-Show par Tranche de Distance à la Clinique (distance_to_clinic_km)	La distance domicile-clinique influence-t-elle l'assiduité aux rendez-vous ?	La distance varie de 0,5 à 45 km ; un effet distance confirmerait un besoin d'options de RDV à distance (téléconsultation) pour les patients éloignés.

5. Approche d'Analyse Initiale

L'analyse se déroulera en plusieurs étapes progressives, alignées sur les phases du projet HealthConnect (Problem Understanding → Analysis and Solution Design → Development) :

1. Nettoyage des données : recodage de reminder_channel (distinction rappel non envoyé vs canal non renseigné), traitement des valeurs manquantes marginales sur distance_to_clinic_km et waiting_time_minutes, vérification de la cohérence des dates (booking_date antérieure à appointment_date).
2. Analyse exploratoire univariée : distribution de chaque variable, en particulier autour de la variable cible appointment_outcome.
3. Analyse bivariée : calcul du taux de no-show pour chaque KPI identifié ci-dessus (croisement avec reminder_sent, booking_lead_days en tranches, previous_no_shows, distance_to_clinic_km en tranches, appointment_type, appointment_day).
4. Priorisation des facteurs : identification des 2-3 facteurs présentant la relation la plus forte avec le no-show, pour orienter les recommandations opérationnelles et alimenter les autres pistes du projet (Data Science pour la modélisation prédictive, Generative AI pour le contenu des rappels).

5. Formalisation des insights et recommandations à destination du management de la clinique, dans la continuité de la structure déjà utilisée lors des semaines précédentes du programme.