

Week 4 Project Summary

HealthConnect Clinic — Data Analytics Track

1. Problème traité par ma piste

En tant qu'intern sur la piste Data Analytics, ma responsabilité est de comprendre les données de rendez-vous d'HealthConnect Clinic afin d'identifier les facteurs associés aux rendez-vous manqués (no-shows), de formuler des questions business pertinentes, et de proposer des indicateurs de performance (KPIs) qui guideront l'analyse approfondie dans les semaines suivantes. Cette contribution alimentera directement la question centrale du projet : comment utiliser la donnée et l'IA pour réduire les no-shows et améliorer l'expérience patient.

2. Ressources utilisées

- HealthConnect_Appointment_Data.csv — dataset de 5 000 rendez-vous, 18 variables.
- HealthConnect_Data_Dictionary — description des variables, utilisée pour interpréter correctement chaque colonne avant toute analyse.

3. Observations clés de la Semaine 4

- Le taux de no-show global observé est de 48,46% (2 423 rendez-vous sur 5 000) — un niveau très élevé qui confirme l'ampleur du problème business décrit dans le scénario.
- Le dataset est globalement propre : aucun doublon, et seulement 3 colonnes présentent des valeurs manquantes (reminder_channel à 27,32%, distance_to_clinic_km à 1,80%, waiting_time_minutes à 1,20%).
- L'absence de reminder_channel semble structurelle plutôt qu'accidentelle : elle coïncide probablement avec les rendez-vous où aucun rappel n'a été envoyé, une hypothèse à confirmer en Semaine 5.
- Le dataset couvre bien les catégories de facteurs pertinents pour l'analyse des no-shows : historique patient, délai de réservation, canal de rappel, distance à la clinique — une base solide pour la suite du projet.

4. Approche proposée

L'approche retenue est progressive : nettoyage ciblé des données (recodage de reminder_channel, traitement des valeurs manquantes marginales), puis analyse exploratoire univariée et bivariée centrée sur la variable appointment_outcome, avant de calculer les 5 KPIs potentiels identifiés dans l'Initial Analysis Document et de les prioriser selon leur pouvoir explicatif du no-show.

5. Considérations clés pouvant affecter le projet

- Le taux de no-show de 48,46% est nettement supérieur aux standards habituels du secteur (10-30%) — à interpréter avec prudence, ce niveau pouvant résulter d'un choix de conception du dataset fictif plutôt que d'une situation strictement réaliste.

- Les valeurs manquantes sur reminder_channel nécessitent une clarification avant tout calcul de KPI lié aux rappels, sous peine de biaiser les résultats si elles sont mal interprétées (manquant au hasard vs absence structurelle).
- Cette analyse reste corrélationnelle à ce stade — établir un lien de causalité entre un facteur (ex: distance, rappel) et le no-show nécessitera une analyse plus poussée, en coordination avec la piste Data Science pour la modélisation prédictive.

6. Focus proposé pour la Semaine 5

Calcul effectif des 5 KPIs identifiés, construction des visualisations associées, et priorisation des 2-3 facteurs présentant la relation la plus forte avec le no-show, en vue de formuler des premières recommandations opérationnelles pour la clinique.